

Plano de Trabalho

Otimização Combinatória para Geração de Árvores de Decisão

Aluna: Sofia Valverde Villas Bôas

Orientador: Prof. Dr. Rafael Crivellari Saliba Schouery

1 Introdução

Suponha que um laboratório necessite estimar a eficácia de um medicamento em desenvolvimento, considerando características como idade, sexo e dosagem prescrita para os indivíduos.

Junta esses dois parágrafos

Uma forma de abordar este problema é através de *árvores de decisão*, técnica utilizada para categorização de dados em classes [1]. No exemplo acima, cada classe está relacionada a um grau de eficácia do medicamento. A categorização ilustrada na Figura 1 ocorre através de uma série de perguntas, representadas pelos retângulos, referentes às características do conjunto de dados.




Figura 1: Árvore de decisão para fabricação de um medicamento hipotético. 📄

Uma vantagem associada a estas árvores é a facilidade de extrair informações relevantes, conceito chamado de *explicabilidade* [2–4]. Assim, estas árvores tornam evidente quais atributos foram mais importantes para a tomada de decisão. No exemplo, se os primeiros níveis da árvore envolvem variáveis como dosagem ou idade, isso indica que tais atributos têm forte correlação com o grau de eficácia do medicamento. 💬

Algoritmos para geração de *árvores de decisão* tradicionalmente [1] 📄 constroem de forma heurística, realizando recursivamente escolhas locais ótimas em cada nó. Apesar de obter resultados razoáveis na prática [5], este processo pode deixar de capturar pontos essenciais dos datasets [2]. 📄

Em 2017, foi proposta por Bertsimas e Dunn [2] a possibilidade de gerar árvores de decisão *ótimas*. Ao construir globalmente a árvore que melhor representa os dados, esta técnica permite aliar explicabilidade e precisão na categorização. 📄

Contudo, o problema de gerar árvores ótimas é NP-Difícil [6], ou seja, não se conhecem

algoritmos que o resolvam em tempo polinomial. Esta complexidade contrasta com o potencial de aplicação destas árvores na resolução de problemas práticos, como no cálculo de risco em cirurgias de emergência [7], no aumento da segurança dinâmica em sistemas de energia elétrica [8] ou (co)car). Apesar de útil, o impacto do uso deste método impulsiona a busca por soluções de qualidade.

Nesse sentido, é possível formular o problema utilizando técnicas de Programação Linear Inteira (PLI), de modo a buscar a otimização de características como interpretabilidade, justiça, esparsabilidade, altura ou acurácia.

Este estudo dirigido terá como objetivo principal o estudo de técnicas de PLI, em paralelo com a leitura de artigos sobre modelos e funcionamento de árvores de decisão. A partir disso, será possível o estudo da otimalidade nestas árvores, bem como a análise do impacto de possíveis formulações e características a serem otimizadas.

2 Metodologia

Em seguida, são apresentados alguns conceitos importantes que serão estudados ao longo do estudo dirigido.

2.1 Programação Linear Inteira

Programação Linear (PL) é uma técnica utilizada no processo de modelagem e resolução de problemas de otimização [9]. Estes problemas envolvem a busca pela melhor solução, segundo um critério de custo ou valor, dentro de um conjunto enumerável de possibilidades. Um programa linear na forma padrão é escrito como:

$$\text{maximize} \quad \sum_{j=1}^n c_j x_j \quad (1)$$

$$\text{sujeito a} \quad \sum_{j=1}^n a_{ij} x_j \leq b_i \quad i = 1, \dots, m \quad (2)$$

$$x_j \geq 0 \quad j = 1, \dots, n \quad (3)$$

A [Equação 1](#) descreve a *função objetivo*, isto é, a função linear que será maximizada (ou minimizada) em um programa linear, no qual x_j são chamadas de *variáveis de decisão*. A [Equação 2](#) representa as *restrições* que delimitam os possíveis valores destas variáveis. Por fim, a [Equação 3](#) indica uma *restrição de não negatividade*, já que em muitos problemas não faz sentido atribuir valores negativos para as variáveis de decisão.

Denomina-se *solução viável* uma atribuição de valores a x_j que satisfaz todas as restrições impostas ao problema. Já uma *solução ótima* é uma solução viável que maximiza a função objetivo. Vale destacar que podem existir mais de uma solução ótima para o mesmo problema ou até mesmo não existir solução ótima. No caso de não existir nenhuma solução viável, o problema é chamado de *inviable* e, para o caso em que as soluções viáveis permitem que a função objetivo cresça indefinidamente, os problemas são chamados de *ilimitados* [\[9\]](#).

Entre as técnicas utilizadas para resolver problemas de PL, está o *método simplex* [\[9\]](#). A partir de uma solução viável inicial, o *simplex* iterativamente realiza o processo de pivotamento, isto é, a troca de variáveis, com o objetivo de melhorar o valor da função objetivo. Apesar de ter complexidade exponencial no pior caso, o *simplex* apresenta desempenho eficiente na prática.

Um *Programa Linear Inteiro* (PLI) é um PL com a restrição adicional de que todas as variáveis devem assumir valores inteiros. Problemas de PLI são NP-Completo, enquanto os problemas de PL pertencem à classe P . Na prática, é possível resolver instâncias específicas de PLI de forma eficiente, graças ao desenvolvimento de algoritmos exatos,

técnicas de otimização e heurísticas eficazes [10].

A *relaxação linear* do PLI consiste em remover as restrições de integralidade de um problema, permitindo que as variáveis inteiras assumam valores contínuos [10]. Dessa forma, é possível utilizar métodos, como o simplex, para obter limites superiores para o valor ótimo do PLI original.

2.2 Árvores de Decisão

Através de uma série de perguntas referentes a características de itens de determinado conjunto de dados, árvores de decisão são capazes de classificá-los em categorias. Elas podem ser usadas, por exemplo, para prever a eficácia de um novo medicamento para pacientes, com base em critérios como dosagem, idade, altura ou peso.

Essas estruturas são compostas de nós internos, que estão associados a perguntas feitas sobre atributos dos dados, e folhas, que se referem às categorias designadas. Elas são construídas a partir de dados em que se conhecem as categorias, processo chamado de *treinamento*. Assim, após essa etapa, são utilizados dados novos, de categorias desconhecidas, de modo a fazer previsões sobre eles.

No processo de construção das árvores de decisão, um dos objetivos é dividir os dados em subgrupos cada vez mais homogêneos. Uma das formas de fazer isso é utilizar o *grau de impureza*, por meio de medidas como o *Índice de Gini*, *Entropia* ou *Razão de Ganho* [Kotsiantis2013].

Existem diversos algoritmos para a geração dessas árvores, sendo um dos mais influentes o algoritmo CART (Classification and Regression Trees) [1], em que são utilizadas medidas de impurezas citadas acima para construir árvores binárias recursivamente. Além disso, o algoritmo aplica técnicas de poda, para evitar o *sobreajuste* dos dados, isto é, quando o modelo se ajusta excessivamente ao conjunto de treinamento, perdendo a capacidade de generalizar para novos dados.

Algumas características são fundamentais para obter modelos mais aplicáveis ao utilizar árvores de decisão. A explicabilidade está relacionada à facilidade com que pessoas

podem entender as decisões do modelo. Essa característica é essencial em áreas como medicina ou direito, onde a explicação das decisões é crítica na resolução de problemas. O quão explicável é um modelo está relacionado com alguns outros fatores, como o tamanho da árvore e a forma como os cortes são feitos [3].

A esparsidade se refere ao uso de um número reduzido de atributos para tomar boas decisões, o que contribui para a simplicidade do modelo. Também vale mencionar a justiça, para que o modelo não propague vieses presentes nos dados, sendo um tema crucial e de interesse crescente na área de aprendizado de máquina.

Nesse contexto, o uso de PLI surge como ferramenta na construção ótima de árvores de decisão, indo além dos métodos heurísticos tradicionais e possibilitando avanços no equilíbrio entre explicabilidade sem a perda de acurácia, minimização da complexidade e respeito dos critérios de justiça, garantindo soluções que são não apenas precisas, mas também interpretáveis e éticas.

3 Atividades do Estudo Dirigido

O primeiro passo consistirá no estudo mais aprofundado de Programação Linear Inteira, baseando-se especialmente nos livros de Wolsey [10] e Chvátal [9]. Paralelamente, a aluna também irá aprofundar os conhecimentos sobre árvores de decisão, de modo a conseguir perceber nuances, limitações e potencialidades desses modelos em diferentes contextos.

Em seguida, o estudo avançará para a análise de como PLI pode ser utilizada para otimizar características relevantes em árvores de decisão. Artigos que exploram essas aplicações serão analisados, destacando abordagens que formalizam a construção da árvore ótima como um problema de otimização inteira, permitindo controlar a complexidade, a explicabilidade e a justiça do modelo [2].

Referências

- [1] L. Breiman, J. Friedman, C. Stone e R. Olshen, *Classification and Regression Trees*. Taylor & Francis, 1984, ISBN: 9780412048418.

- [2] D. Bertsimas e J. Dunn, “Optimal classification trees,” *Machine Learning*, v. 106, n. 7, 2017, ISSN: 1573-0565. DOI: [10.1007/s10994-017-5633-9](https://doi.org/10.1007/s10994-017-5633-9).
- [3] V. G. Costa e C. E. Pedreira, “Recent advances in decision trees: an updated survey,” *Artificial Intelligence Review*, 2022. DOI: [10.1007/s10462-022-10275-5](https://doi.org/10.1007/s10462-022-10275-5).
- [4] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, v. 1, n. 5, 2019, ISSN: 2522-5839. DOI: [10.1038/s42256-019-0048-x](https://doi.org/10.1038/s42256-019-0048-x).
- [5] J. G. M. van der Linden, D. Vos, M. M. de Weerdt, S. Verwer e E. Demirović, *Optimal or Greedy Decision Trees? Revisiting their Objectives, Tuning, and Performance*, 2024. DOI: [10.48550/ARXIV.2409.12788](https://doi.org/10.48550/ARXIV.2409.12788).
- [6] L. Hyafil e R. L. Rivest, “Constructing optimal binary decision trees is NP-complete,” *Information Processing Letters*, v. 5, n. 1, 1976, ISSN: 0020-0190. DOI: [https://doi.org/10.1016/0020-0190\(76\)90095-8](https://doi.org/10.1016/0020-0190(76)90095-8).
- [7] D. Bertsimas, J. Dunn, G. C. Velmahos e H. M. A. Kaafarani, “Surgical Risk Is Not Linear: Derivation and Validation of a Novel, User-friendly, and Machine-learning-based Predictive OpTimal Trees in Emergency Surgery Risk (POTTER) Calculator,” *Annals of Surgery*, v. 268, n. 4, 2018. DOI: [10.1097/SLA.0000000000002956](https://doi.org/10.1097/SLA.0000000000002956).
- [8] I. Genc, R. Diao, V. Vittal, S. Kolluri e S. Mandal, “Decision Tree-Based Preventive and Corrective Control Applications for Dynamic Security Enhancement in Power Systems,” *IEEE Transactions on Power Systems*, v. 25, n. 3, 2010, ISSN: 1558-0679. DOI: [10.1109/tpwrs.2009.2037006](https://doi.org/10.1109/tpwrs.2009.2037006).
- [9] V. Chvátal, *Linear Programming* (Series of books in the mathematical sciences). W. H. Freeman, 1983, ISBN: 9780716715870.
- [10] L. A. Wolsey, *Integer programming*, Second edition. Hoboken, NJ: Wiley, 2021, 1316 pp., Description based upon online resource; title from PDF title page (viewed September 28, 2020), ISBN: 9781119606529.