

Plano de Trabalho

Otimização Combinatória na Geração de Árvores de Decisão

Aluna: Sofia Valverde Villas Bôas

Orientador: Prof. Dr. Rafael Crivellari Saliba Schouery

1 Introdução

No contexto de aprendizado de máquina supervisionado, *árvores de decisão* são uma técnica amplamente utilizada em problemas de classificação e predição. Em um mundo onde a tomada de decisões sensíveis carece cada vez mais de modelos justos, precisos e interpretáveis, o uso de tais árvores se destaca. Isso porque este método tem como grande vantagem a explicabilidade a ele associada [1, 8] e, portanto, é bastante útil em diversas aplicações.

Tradicionalmente, algoritmos para geração de árvores de decisão as constroem recursivamente de forma heurística, realizando escolhas locais ótimas em cada nó. Apesar de obter resultados razoáveis na prática [9], este processo pode deixar de capturar pontos essenciais dos datasets.

Assim, como proposto por Bertsimas e Dunn [1], é possível gerar árvores de decisão ótimas. Essas árvores vêm sendo relevantes na resolução de problemas práticos, como no cálculo de risco em cirurgias de emergência [2]. Entretanto, foi demonstrado que esse problema é NP-Difícil [6], ou seja, não se conhecem algoritmos que o resolvam em tempo polinomial.

Nesse sentido, é possível formular o problema utilizando técnicas de Programação Linear Inteira (PLI), de modo a buscar a otimização de parâmetros como interpretabilidade, justiça, esparsabilidade, altura ou acurácia.

Este estudo dirigido terá como objetivo principal o estudo de técnicas de PLI, em paralelo com a leitura de artigos sobre modelos e funcionamento de árvores de decisão. A partir disso, será possível o estudo da optimalidade nessas árvores, bem como a análise de possíveis formulações e parâmetros a serem otimizados.

2 Metodologia

Em seguida, são apresentados alguns conceitos importantes que serão estudados ao longo do estudo dirigido.

2.1 Programação Linear Inteira

Programação Linear (PL) é uma técnica muito utilizada no processo de modelagem e resolução de problemas de otimização. Esses tipos de problemas envolvem a busca pela melhor solução, segundo um critério de custo ou valor, dentro de um conjunto finito ou enumerável de possibilidades. Um programa linear na forma padrão é escrito como:

$$\text{maximize} \quad \sum_{j=1}^n c_j x_j \quad (1)$$

$$\text{sujeito a} \quad \sum_{j=1}^n a_{ij} x_j \leq b_i \quad i = 1, \dots, m \quad (2)$$

$$x_j \geq 0 \quad j = 1, \dots, n \quad (3)$$

A Equação 1 descreve a *função objetivo*, isto é, a função linear que será maximizada ou minimizada em um programa linear, onde x_j são chamadas de *variáveis de decisão*. A Equação 2 representa as *restrições* que delimitam os possíveis valores dessas variáveis. Por fim, a Equação 3 indica uma *restrição de não negatividade*, já que em muitos problemas não faz sentido atribuir valores negativos para as variáveis de decisão.

Denomina-se *solução viável* o conjunto de soluções que satisfaz todas as restrições impostas ao problema. Já uma *solução ótima* é uma solução viável que maximiza a função objetivo. Vale destacar que podem existir mais de uma solução ótima para o mesmo problema ou até mesmo não existir solução ótima. No caso de não existir nenhuma solução viável, o problema é chamado de *inviable* e, para o caso em que as soluções viáveis permitem que a função objetivo cresça indefinidamente, os problemas são chamados de *ilimitados* [4].

Entre as técnicas utilizadas para resolver problemas de PL, está o *método simplex*. A partir de uma solução básica viável inicial, o simplex iterativamente realiza o processo de pivotamento, isto é, a troca de variáveis não-básicas por básicas, com o objetivo de melhorar ou manter o valor da função objetivo. Apesar de ser exponencial no pior caso, o simplex apresenta performance eficiente na prática.

Um Programa Linear Inteiro (PLI) é um PL com a restrição adicional de que todas as variáveis devem assumir valores inteiros. Problemas de PLI são NP-Completo, enquanto os problemas de PL pertencem à classe P . Na prática, é possível resolver instâncias

específicas de PLI de forma eficiente, graças ao desenvolvimento de algoritmos exatos, técnicas de otimização e heurísticas eficazes [10].

A *relaxação linear* do PLI consiste em remover as restrições de integralidade de um problema, permitindo que as variáveis inteiras assumam valores contínuos [10]. Dessa forma, é possível utilizar métodos, como o simplex, para obter limites superiores para o valor ótimo do PLI original.

2.2 Árvores de Decisão

Através de uma série de perguntas referentes a características de itens de determinado conjunto de dados, árvores de decisão são capazes de classificá-los em categorias. Elas podem ser usadas, por exemplo, para prever a eficácia de um novo medicamento para pacientes, com base em critérios como dosagem, idade, altura ou peso.

Essas estruturas são compostas de nós internos, que estão associados a perguntas feitas sobre atributos dos dados, e folhas, que se referem às categorias designadas. Elas são construídas a partir de dados em que se conhecem as categorias, processo chamado de *treinamento*. Assim, após essa etapa, são utilizados dados novos, de categorias desconhecidas, de modo a fazer previsões sobre eles.

No processo de construção das árvores de decisão, um dos objetivos é dividir os dados em subgrupos cada vez mais homogêneos. Uma das formas de fazer isso é utilizar o *grau de impureza*, por meio de medidas como o *Índice de Gini*, *Entropia* ou *Razão de Ganho* [7].

Existem diversos algoritmos para a geração dessas árvores, sendo um dos mais influentes o algoritmo CART (Classification and Regression Trees) [3], em que são utilizadas medidas de impurezas citadas acima para construir árvores binárias recursivamente. Além disso, o algoritmo aplica técnicas de poda, para evitar o *sobreaajuste* dos dados, isto é, quando o modelo se ajusta excessivamente ao conjunto de treinamento, perdendo a capacidade de generalizar para novos dados.

Alguns parâmetros são fundamentais para obter modelos mais aplicáveis ao utilizar árvores de decisão. A explicabilidade está relacionada à facilidade com que pessoas podem entender as decisões do modelo. Essa característica é essencial em áreas como medicina ou direito, onde a explicação das decisões é crítica na resolução de problemas. O quão explicável é um modelo está relacionado com alguns outros fatores, como o tamanho da árvore e a forma como os cortes são feitos [5].

A esparsidade se refere ao uso de um número reduzido de atributos para tomar boas decisões, o que contribui para a simplicidade do modelo. Também vale mencionar a justiça, para que o modelo não propague viéses presentes nos dados, sendo um tema crucial e de interesse crescente na área de aprendizado de máquina.

Nesse contexto, o uso de PLI surge como ferramenta na construção ótima de árvores de decisão, indo além dos métodos heurísticos tradicionais e possibilitando avanços no equilíbrio entre explicabilidade sem a perda de acurácia, minimização da complexidade e respeito dos critérios de justiça, garantindo soluções que são não apenas precisas, mas também interpretáveis e éticas.

3 Atividades do Estudo Dirigido

Esse estudo dirigido terá, portanto, algumas atividades e objetivos principais.

O primeiro passo consistirá no estudo mais aprofundado de Programação Linear Inteira, baseando-se especialmente nos livros de Wolsey [10] e Chvátal [4]. Paralelamente, a aluna também irá aprofundar os conhecimentos sobre árvores de decisão, de modo a conseguir perceber nuances, limitações e potencialidades desses modelos em diferentes contextos.

Em seguida, o estudo avançará para a análise de como PLI pode ser utilizada para otimizar parâmetros relevantes em árvores de decisão. Artigos que exploram essas aplicações serão analisados, destacando abordagens que formalizam a construção ótima da árvore como um problema de otimização inteira, permitindo controlar a complexidade, a explicabilidade e a justiça do modelo [1].

Referências

- [1] Dimitris Bertsimas and Jack Dunn. Optimal classification trees. *Machine Learning*, 106:1039–1082, 2017.
- [2] Dimitris Bertsimas, Jack Dunn, George C. Velmahos, and Haytham M. A. Kaafarani. Surgical risk is not linear: Derivation and validation of a novel, user-friendly, and machine-learning-based predictive optimal trees in emergency surgery risk (potter) calculator. *Annals of Surgery*, 268(4):574–583, October 2018.
- [3] L. Breiman, J. Friedman, C.J. Stone, and R.A. Olshen. *Classification and Regression Trees*. Taylor & Francis, 1984.
- [4] V. Chvátal. *Linear Programming*. Series of books in the mathematical sciences. W. H. Freeman, 1983.
- [5] Vinícius G. Costa and Carlos E. Pedreira. Recent advances in decision trees: an updated survey. *Artificial Intelligence Review*, 56(5):4765–4800, May 2023.

- [6] Laurent Hyafil and Ronald L. Rivest. Constructing optimal binary decision trees is np-complete. *Information Processing Letters*, 5(1):15–17, 1976.
- [7] S. B. Kotsiantis. Decision trees: a recent overview. *Artificial Intelligence Review*, 39(4):261–283, 2013.
- [8] Jacobus van der Linden, Mathijs de Weerdt, and Emir Demirović. Fair and optimal decision trees: A dynamic programming approach. In S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems*, volume 35, pages 38899–38911. Curran Associates, Inc., 2022.
- [9] Jacobus G. M. van der Linden, Daniël Vos, Mathijs M. de Weerdt, Sicco Verwer, and Emir Demirović. Optimal or greedy decision trees? revisiting their objectives, tuning, and performance.
- [10] L.A. Wolsey. *Integer Programming*. Wiley, 2020.