

Plano de Trabalho

Otimização Combinatória para Geração de Árvores de Decisão

Aluna: Sofia Valverde Villas Bôas

Orientador: Prof. Dr. Rafael Crivellari Saliba Schouery

1 Introdução

Suponha que um laboratório necessite estimar a eficácia de um medicamento em desenvolvimento, considerando características como idade, sexo e dosagem receitada para os indivíduos. Uma forma de abordar este problema é por meio de *árvores de decisão*, técnica utilizada para categorização de dados em classes [1]. No exemplo, cada classe está relacionada a um grau de eficácia do medicamento. A categorização ilustrada na Figura 1 ocorre via uma série de perguntas, representadas pelos retângulos, referentes às características do conjunto de dados.




Figura 1: Árvore de decisão para fabricação de um medicamento hipotético. Nós internos (retângulos) da árvore representam perguntas aplicadas a características dos dados. As ligações ("verdadeiro" ou "falso") correspondem ao caminho a seguir dependendo do resultado da pergunta. Os nós folhas são classes alvo do problema, isto é, os níveis de eficácia do medicamento.

Uma vantagem associada a estas árvores é a facilidade de extrair informações relevantes, conceito chamado de *explicabilidade* [2–4]. Assim, estas árvores evidenciam quais atributos foram mais importantes para a tomada de decisão. Por exemplo, o medicamento funciona eficientemente para pacientes do sexo masculino, com até 60 anos e receberam dosagem acima de 35. Este agrupamento facilita a interpretação do modelo e a obtenção de novas hipóteses.

Algoritmos para geração de *árvores de decisão* tradicionalmente as constroem de forma heurística, realizando recursivamente escolhas locais ótimas em cada nó [1]. Apesar de obter resultados razoáveis na prática [5], este processo pode deixar de capturar pontos essenciais dos *datasets* [2].

Em 2017, Bertsimas e Dunn [2] propuseram a possibilidade de gerar árvores de decisão *ótimas*. Ao construir globalmente a árvore que melhor representa os dados, esta técnica permite aliar explicabilidade e precisão na categorização.

Contudo, o problema de gerar árvores ótimas é NP-Difícil [6], ou seja, não se conhecem algoritmos que o resolvam em tempo polinomial. Esta complexidade contrasta com o potencial de aplicação destes modelos na resolução de problemas práticos, como no cálculo de risco em cirurgias de emergência [7], no aumento da segurança dinâmica em sistemas de energia elétrica [8] ou na recomendação de políticas sociais [9]. Apesar de difícil, o impacto do uso deste método evidencia a necessidade de desenvolver algoritmos computacionalmente eficazes.

Nesse sentido, é possível formular o problema utilizando técnicas de Programação Linear Inteira (PLI), de modo a buscar a otimização de características como explicabilidade, justiça, esparsabilidade, altura ou acurácia, a serem aprofundadas na Seção 2.

Este estudo dirigido terá como objetivo principal o estudo de técnicas de PLI, em paralelo com a leitura de artigos sobre modelos e funcionamento de árvores de decisão. A partir disso, será possível o estudo da otimalidade nestas árvores, bem como a análise do impacto de possíveis formulações e características a serem otimizadas. Além disso, buscamos introduzir a aluna às práticas acadêmicas, contribuindo para sua formação e eventual iniciação científica.

2 Metodologia

Em seguida, são apresentados alguns conceitos importantes que serão estudados ao longo do estudo dirigido.

2.1 Programação Linear Inteira

Programação Linear (PL) é uma técnica utilizada no processo de modelagem e resolução de problemas de otimização [10]. Estes problemas envolvem a busca pela melhor solução,

segundo um critério de custo ou valor, em um conjunto enumerável de possibilidades. Um programa linear na forma padrão é escrito como:

$$\text{maximize} \quad \sum_{j=1}^n c_j x_j \quad (1)$$

$$\text{sujeito a} \quad \sum_{j=1}^n a_{ij} x_j \leq b_i \quad i = 1, \dots, m \quad (2)$$

$$x_j \geq 0 \quad j = 1, \dots, n \quad (3)$$

A Equação 1 descreve a *função objetivo*, isto é, a função linear que será maximizada (ou minimizada) em um programa linear, no qual x_j são chamadas de *variáveis de decisão*. A Equação 2 representa as *restrições* que delimitam os possíveis valores destas variáveis. Por fim, a Equação 3 indica uma *restrição de não negatividade*, já que em muitos problemas não faz sentido atribuir valores negativos para as variáveis de decisão.

Denomina-se *solução viável* uma atribuição de valores a x_j que satisfaz todas as restrições impostas ao problema. Já uma *solução ótima* é uma solução viável que maximiza a função objetivo. Vale destacar que podem existir mais de uma solução ótima para o mesmo problema ou até mesmo não existir solução ótima. No caso de não existir nenhuma solução viável, o problema é chamado de *inviable* e, para o caso em que as soluções viáveis permitem que a função objetivo cresça indefinidamente, os problemas são chamados de *ilimitados* [10].

Entre as técnicas utilizadas para resolver problemas de PL, está o *método simplex* [10]. A partir de uma solução viável inicial, o *simplex* realiza iterativamente o processo de pivotamento, isto é, a troca de variáveis, visando melhorar o valor da função objetivo. Apesar de ter complexidade exponencial no pior caso, o *simplex* apresenta desempenho eficiente, na prática.

Um *Programa Linear Inteiro* (PLI) é um PL com a restrição adicional de que todas as variáveis devem assumir valores inteiros. Problemas de PLI são NP-Completo, mas,

na prática, é possível resolver instâncias específicas de PLI de forma eficiente, graças ao desenvolvimento de algoritmos exatos, técnicas de otimização e heurísticas eficazes [11].

2.2 Árvores de Decisão

Mediante uma série de perguntas referentes a características de itens de determinado conjunto de dados, árvores de decisão são capazes de classificá-los em categorias. Assim como no exemplo da Introdução, elas podem ser usadas em diversas aplicações, como na área da medicina [12, 13] ou na de finanças [14].

Árvores de decisão são compostas de nós internos, que estão associados a perguntas feitas sobre atributos dos dados, e folhas, as quais são atribuídas às categorias designadas. Elas são construídas a partir de dados em que se conhecem as categorias, processo chamado de *treinamento*. Após essa etapa, ao utilizar dados ainda não vistos, pode-se validar a previsão feita ao classificá-los corretamente.

Existem diversos algoritmos para a geração dessas árvores, sendo um dos mais influentes o algoritmo CART (Classification and Regression Trees) [1], o qual utiliza formas heurísticas para tomar decisões locais, em que são utilizadas medidas de impurezas como o *Índice de Gini*, *Entropia* ou *Razão de Ganho* [15].

Além disso, o algoritmo aplica técnicas de poda, para evitar o *sobreajuste* dos dados, isto é, quando o modelo se ajusta excessivamente ao conjunto de treinamento, perdendo a capacidade de generalizar para novos dados.

Algumas características são fundamentais para obter modelos mais aplicáveis ao utilizar árvores de decisão. A explicabilidade, mencionada na Introdução, é útil em domínios onde as decisões precisam ser justificáveis, como medicina ou direito. No entanto, o quão explicável é um modelo está relacionado com alguns outros fatores, como o tamanho da árvore e como os cortes são feitos [3].

A *esparsidade* se refere ao uso de um número reduzido de atributos para categorizar, o que contribui para a simplicidade do modelo e proporciona maior explicabilidade. Também vale mencionar a *justiça*, para que o modelo não propague viéses presentes nos

dados, sendo um tema crucial e de interesse crescente na área de aprendizado de máquina.

Nesse contexto, o uso de PLI surge como ferramenta na construção ótima de árvores de decisão, indo além dos métodos heurísticos tradicionais e possibilitando avanços no equilíbrio entre explicabilidade sem a perda de acurácia, minimização da complexidade e respeito dos critérios de justiça, garantindo soluções que são não apenas precisas, mas também interpretáveis e éticas.

3 Atividades do Estudo Dirigido

O primeiro passo consistirá no estudo mais aprofundado de Programação Linear Inteira, baseando-se especialmente nos livros de Wolsey [11] e Chvátal [10]. Paralelamente, a aluna também irá aprofundar os conhecimentos sobre árvores de decisão, de modo a conseguir perceber nuances, limitações e potencialidades desses modelos em diferentes contextos.

Em seguida, o estudo avançará para a análise de como PLI pode ser utilizada para otimizar características relevantes em árvores de decisão. Artigos que exploram essas aplicações serão analisados, destacando abordagens que formalizam a construção da árvore ótima como um problema de otimização inteira, permitindo controlar a complexidade, a explicabilidade e a justiça do modelo [2].

Referências

- [1] L. Breiman, J. Friedman, C. Stone e R. Olshen, *Classification and Regression Trees*. Taylor & Francis, 1984, ISBN: 9780412048418.
- [2] D. Bertsimas e J. Dunn, “Optimal classification trees,” *Machine Learning*, v. 106, n. 7, 2017, ISSN: 1573-0565. DOI: 10.1007/s10994-017-5633-9.
- [3] V. G. Costa e C. E. Pedreira, “Recent advances in decision trees: an updated survey,” *Artificial Intelligence Review*, 2022. DOI: 10.1007/s10462-022-10275-5.
- [4] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, v. 1, n. 5, 2019, ISSN: 2522-5839. DOI: 10.1038/s42256-019-0048-x.

- [5] J. G. M. van der Linden, D. Vos, M. M. de Weerdt, S. Verwer e E. Demirović, *Optimal or Greedy Decision Trees? Revisiting their Objectives, Tuning, and Performance*, 2024. DOI: 10.48550/ARXIV.2409.12788.
- [6] L. Hyafil e R. L. Rivest, “Constructing optimal binary decision trees is NP-complete,” *Information Processing Letters*, v. 5, n. 1, 1976, ISSN: 0020-0190. DOI: [https://doi.org/10.1016/0020-0190\(76\)90095-8](https://doi.org/10.1016/0020-0190(76)90095-8).
- [7] D. Bertsimas, J. Dunn, G. C. Velmahos e H. M. A. Kaafarani, “Surgical Risk Is Not Linear: Derivation and Validation of a Novel, User-friendly, and Machine-learning-based Predictive OpTimal Trees in Emergency Surgery Risk (POTTER) Calculator,” *Annals of Surgery*, v. 268, n. 4, 2018. DOI: 10.1097/SLA.0000000000002956.
- [8] I. Genc, R. Diao, V. Vittal, S. Kolluri e S. Mandal, “Decision Tree-Based Preventive and Corrective Control Applications for Dynamic Security Enhancement in Power Systems,” *IEEE Transactions on Power Systems*, v. 25, n. 3, 2010, ISSN: 1558-0679. DOI: 10.1109/tpwrs.2009.2037006.
- [9] H. Chan, E. Rice, P. Vayanos, M. Tambe e M. Morton, “From Empirical Analysis to Public Policy: Evaluating Housing Systems for Homeless Youth,” em *Machine Learning and Knowledge Discovery in Databases*. Springer International Publishing, 2019, ISBN: 9783030109974. DOI: 10.1007/978-3-030-10997-4_5.
- [10] V. Chvátal, *Linear Programming* (Series of books in the mathematical sciences). W. H. Freeman, 1983, ISBN: 9780716715870.
- [11] L. A. Wolsey, *Integer programming*, Second edition. Hoboken, NJ: Wiley, 2021, 1316 pp., Description based upon online resource; title from PDF title page (viewed September 28, 2020), ISBN: 9781119606529.
- [12] G. Richards, V. Rayward-Smith, P. Sönksen, S. Carey e C. Weng, “Data mining for indicators of early mortality in a database of clinical records,” *Artificial Intelligence in Medicine*, v. 22, n. 3, 2001, ISSN: 0933-3657. DOI: 10.1016/s0933-3657(00)00110-x.
- [13] A. A. Freitas, “Comprehensible classification models: a position paper,” *ACM SIGKDD Explorations Newsletter*, v. 15, n. 1, 2014, ISSN: 1931-0153. DOI: 10.1145/2594473.2594475.
- [14] V. Dhar, D. Chou e F. Provost, “Discovering Interesting Patterns for Investment Decision Making with GLOWER —A Genetic Learner Overlaid with Entropy Reduction,” *Data Mining and Knowledge Discovery*, v. 4, n. 4, 2000, ISSN: 1573-756X. DOI: 10.1023/a:1009848126475.

- [15] S. Kotsiantis, “Decision trees: a recent overview,” *Artificial Intelligence Review*, 2013. DOI: 10.1007/s10462-011-9272-4.