

Relatório de Estudo Dirigido

Otimização Combinatória para Geração de Árvores de Decisão

Aluna: Sofia Valverde Villas Bôas

RA 252974 - Engenharia de Computação AA

s252974@dac.unicamp.br

Orientador: Prof. Dr. Rafael Crivellari Saliba Schouery

1 Introdução

Suponha que um laboratório necessite estimar a eficácia de um medicamento em desenvolvimento, considerando características como idade, sexo e dosagem prescrita para os indivíduos. Uma forma de abordar este problema é por meio de *árvores de decisão*, técnica utilizada para categorização de dados em classes [**<empty citation>**]. No exemplo, cada classe está relacionada a um grau de eficácia do medicamento. A categorização ilustrada na Figura 1 ocorre via uma série de perguntas, representadas pelos retângulos, referentes às características do conjunto de dados.




Figura 1: Árvore de decisão para fabricação de um medicamento hipotético. Nós internos (retângulos) da árvore representam perguntas aplicadas a características dos dados. As ligações ("verdadeiro" ou "falso") correspondem ao caminho a seguir dependendo do resultado da pergunta. Os nós folhas são classes alvo do problema, isto é, os níveis de eficácia do medicamento.

Uma vantagem associada a estas árvores é a facilidade de extrair informações relevantes, conceito chamado de *explicabilidade* [2, 6, 10]. Assim, estas árvores evidenciam quais atributos foram mais importantes para a tomada de decisão. Por exemplo, o medicamento funciona eficientemente para pacientes do sexo masculino, com até 60 anos e que receberam dosagem acima de 35. Este agrupamento facilita a interpretação do modelo e a obtenção de novas hipóteses.

Algoritmos para geração de *árvores de decisão* tradicionalmente as constroem de forma heurística, realizando recursivamente escolhas locais ótimas em cada nó [6]. Apesar de obter resultados razoáveis na prática [9], este processo pode deixar de capturar pontos essenciais dos *datasets* [2].

Em 2017, Bertsimas e Dunn [2] propuseram a possibilidade de gerar árvores de decisão *ótimas*. Ao construir globalmente a árvore que melhor representa os dados, esta técnica permite aliar explicabilidade e precisão na categorização.

Contudo, o problema de gerar árvores ótimas é NP-Difícil [8], ou seja, não se conhecem algoritmos que o resolvam em tempo polinomial. Esta complexidade contrasta com o potencial de aplicação destes modelos na resolução de problemas práticos, como no cálculo de risco em cirurgias de emergência [3], no aumento da segurança dinâmica em sistemas de energia elétrica [7] ou na recomendação de políticas sociais [4]. Apesar de difícil, o impacto do uso deste método evidencia a necessidade de desenvolver algoritmos computacionalmente eficazes.

Portanto, o objetivo principal deste estudo dirigido consiste no estudo de técnicas de Programação Linear Inteira (PLI) para a formulação do problema, em paralelo com a leitura de artigos sobre modelos e funcionamento de árvores de decisão. A partir disso, partiu-se para o estudo da otimalidade nestas árvores, bem como a análise do impacto de possíveis formulações e características a serem otimizadas. Além disso, buscou-se introduzir a aluna às práticas acadêmicas, contribuindo para sua formação e eventual iniciação científica.

2 Atividades Previstas

O primeiro passo consistiu no estudo mais aprofundado de Programação Linear Inteira, baseando-se especialmente nos livros de Wolsey [12] e Chvátal [5]. Paralelamente, a aluna também aprofundou os conhecimentos sobre árvores de decisão, de modo a conseguir perceber nuances, limitações e potencialidades desses modelos em diferentes contextos.

Em seguida, deu-se a análise de como PLI pode ser utilizada para otimizar características relevantes em árvores de decisão. Artigos que exploram essas aplicações como [1, 6, 11] foram analisados, destacando abordagens que formalizam a construção da árvore ótima como um problema de otimização inteira, permitindo controlar a complexidade, a

explicabilidade e a justiça do modelo [2].

3 Resultados

Em seguida, são apresentados os principais tópicos estudados ao longo do período do estudo dirigido.

3.1 Programação Linear Inteira

Falar que aprendi os fundamentos das técnicas que vou usar na IC

- PL e simplex - PLI, dualidade, convex hull, branch and bound, cutting plane...

3.2 Árvores de Decisão Ótimas

- possíveis formulações.

3.3 Implementações e Experimentos

Falar que aprendi a mexer no GUROBI, me familiarizando com o solver através da implementação de um modelo simples.

4 Conclusão

Durante o Estudo Dirigido, diversos aspectos colaboraram para o amadurecimento profissional e acadêmico da aluna. Entre eles, é importante mencionar a construção de uma base de conhecimentos em Programação Linear Inteira. Através tanto do estudo individual, como das reuniões do grupo de pesquisa semanais, a aluna consolidou o entendimento de técnicas de PLI e como elas são aplicadas no contexto de otimização.

Além disso, a leitura de artigos sobre árvores de decisão ótimas colaborou para a compreensão do contexto de uso dessa técnica de categorização...

- Matérias do curso que eu usei:

Referências

- [1] S. Aghaei, A. Gómez e P. Vayanos, *Strong Optimal Classification Trees*, 2021. DOI: 10.48550/ARXIV.2103.15965.
- [2] D. Bertsimas e J. Dunn, “Optimal classification trees,” *Machine Learning*, v. 106, n. 7, 2017, ISSN: 1573-0565. DOI: 10.1007/s10994-017-5633-9.
- [3] D. Bertsimas, J. Dunn, G. C. Velmahos e H. M. A. Kaafarani, “Surgical Risk Is Not Linear: Derivation and Validation of a Novel, User-friendly, and Machine-learning-based Predictive OpTimal Trees in Emergency Surgery Risk (POTTER) Calculator,” *Annals of Surgery*, v. 268, n. 4, 2018. DOI: 10.1097/SLA.0000000000002956.
- [4] H. Chan, E. Rice, P. Vayanos, M. Tambe e M. Morton, “From Empirical Analysis to Public Policy: Evaluating Housing Systems for Homeless Youth,” em *Machine Learning and Knowledge Discovery in Databases*. Springer International Publishing, 2019, ISBN: 9783030109974. DOI: 10.1007/978-3-030-10997-4_5.
- [5] V. Chvátal, *Linear Programming* (Series of books in the mathematical sciences). W. H. Freeman, 1983, ISBN: 9780716715870.
- [6] V. G. Costa e C. E. Pedreira, “Recent advances in decision trees: an updated survey,” *Artificial Intelligence Review*, v. 56, n. 5, 2022, ISSN: 1573-7462. DOI: 10.1007/s10462-022-10275-5.
- [7] I. Genc, R. Diao, V. Vittal, S. Kolluri e S. Mandal, “Decision Tree-Based Preventive and Corrective Control Applications for Dynamic Security Enhancement in Power Systems,” *IEEE Transactions on Power Systems*, v. 25, n. 3, 2010, ISSN: 1558-0679. DOI: 10.1109/tpwrs.2009.2037006.
- [8] L. Hyafil e R. L. Rivest, “Constructing optimal binary decision trees is NP-complete,” *Information Processing Letters*, v. 5, n. 1, 1976, ISSN: 0020-0190. DOI: 10.1016/0020-0190(76)90095-8.
- [9] J. G. M. van der Linden, D. Vos, M. M. de Weerdt, S. Verwer e E. Demirović, *Optimal or Greedy Decision Trees? Revisiting their Objectives, Tuning, and Performance*, 2024. DOI: 10.48550/ARXIV.2409.12788.
- [10] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, v. 1, n. 5, 2019, ISSN: 2522-5839. DOI: 10.1038/s42256-019-0048-x.

- [11] S. Verwer e Y. Zhang, “Learning Optimal Classification Trees Using a Binary Linear Program Formulation,” *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 33, n. 01, 2019, ISSN: 2159-5399. DOI: 10.1609/aaai.v33i01.33011624.
- [12] L. A. Wolsey, *Integer programming*, Second edition. Hoboken, NJ: Wiley, 2021, 1316 pp., Description based upon online resource; title from PDF title page (viewed September 28, 2020), ISBN: 9781119606529.