

Relatório de Estudo Dirigido

Otimização Combinatória para Geração de Árvores de Decisão

Aluna: Sofia Valverde Villas Bôas

RA 252974 - Engenharia de Computação AA

s252974@dac.unicamp.br

Orientador: Prof. Dr. Rafael Crivellari Saliba Schouery

1 Introdução

Suponha que um laboratório necessite estimar a eficácia de um medicamento em desenvolvimento, considerando características como idade, sexo e dosagem receitada para os indivíduos. Uma forma de abordar este problema é por meio de *árvores de decisão*, técnica utilizada para categorização de dados em classes [2]. No exemplo, cada classe está relacionada a um grau de eficácia do medicamento. A categorização ilustrada na Figura 1 ocorre via uma série de perguntas, representadas pelos retângulos, referentes às características do conjunto de dados.




Figura 1: Árvore de decisão para fabricação de um medicamento hipotético. Nós internos da árvore representam perguntas aplicadas às características dos dados. As ligações correspondem ao caminho a seguir dependendo do resultado da pergunta. Os nós folhas são classes alvo do problema, isto é, os níveis de eficácia do medicamento.

Uma vantagem associada a estas árvores é a facilidade de extrair informações relevantes, conceito chamado de *explicabilidade* [2, 6, 11]. Assim, estas árvores evidenciam quais atributos foram mais importantes para a tomada de decisão. Por exemplo, o medicamento funciona eficientemente para pacientes do sexo masculino, com até 60 anos e que receberam dosagem acima de 35. Este agrupamento facilita a interpretação do modelo e a obtenção de novas hipóteses.

Algoritmos para geração de *árvores de decisão* tradicionalmente as constroem de forma heurística, realizando recursivamente escolhas locais ótimas em cada nó [6]. Apesar de obter resultados razoáveis na prática [10], este processo pode deixar de capturar pontos essenciais dos *datasets* [2].

Em 2017, Bertsimas e Dunn [2] propuseram a possibilidade de gerar árvores de decisão *ótimas*. Ao construir globalmente a árvore que melhor representa os dados, esta técnica permite aliar explicabilidade e precisão na categorização.

Contudo, o problema de gerar árvores ótimas é NP-Difícil [9], ou seja, não se conhece algoritmos que o resolva em tempo polinomial. Esta complexidade contrasta com o potencial de aplicação destes modelos na resolução de problemas práticos, como no cálculo de risco em cirurgias de emergência [3], no aumento da segurança dinâmica em sistemas de energia elétrica [7] ou na recomendação de políticas sociais [4]. Apesar de difícil, o impacto do uso deste método evidencia a necessidade de desenvolver algoritmos computacionalmente eficientes.

Portanto, o objetivo principal deste Estudo Dirigido consiste no estudo de técnicas de Programação Linear Inteira (PLI) para a formulação do problema, em paralelo com a leitura de artigos sobre modelos e funcionamento de árvores de decisão. A partir disso, estudamos a otimalidade nestas árvores, bem como a análise do impacto de possíveis formulações e características a serem otimizadas. De forma complementar, o projeto busca introduzir a aluna às práticas acadêmicas, contribuindo para sua formação e eventual iniciação científica.

2 Atividades

O primeiro passo compreendeu o estudo dos fundamentos de Programação Linear Inteira, utilizando os livros de Wolsey [13] e Chvátal [5]. Paralelamente, a aluna também aprofundou os conhecimentos sobre árvores de decisão, de modo a conseguir perceber nuances, limitações e potencialidades desses modelos em diferentes contextos.

Em seguida, deu-se a análise de como PLI pode ser utilizada para otimizar características relevantes em árvores de decisão. Entre as referências consultadas, os trabalhos de Aghaei et al. [1], Verwer e Zhang [12] e Costa et al. [6] exploram diferentes formulações e objetivos de otimização para árvores de decisão ótimas.

Adicionalmente, o acompanhamento semanal das reuniões da equipe de pesquisa foi importante para a troca de conhecimentos e esclarecimento de dúvidas ao longo do Estudo Dirigido. Neste contexto, a estudante realizou um seminário acerca da formulação de Verwer e Zhang [12].

Por fim, a aluna também se familiarizou com o uso de *solvers* de PLI, como o *software* Gurobi [8], ao implementar a formulação proposta por Aghaei et al. [1]. Essa etapa foi fundamental para a consolidação dos conceitos teóricos estudados ao longo do período.

3 Resultados

Em seguida, são apresentados os principais tópicos estudados ao longo do período do Estudo Dirigido.

3.1 Programação Linear Inteira

Ao decorrer do Estudo Dirigido, foram estudados diversos conceitos fundamentais de Programação Linear e Programação Linear Inteira.

Programação Linear (PL) é uma técnica utilizada no processo de modelagem e resolução de problemas de otimização [5]. Estes problemas envolvem a busca pela melhor solução, segundo um critério de custo ou valor, em um conjunto enumerável de possibilidades. Um programa linear na forma padrão é escrito como:

$$\text{maximize} \quad \sum_{j=1}^n c_j x_j \quad (1)$$

$$\text{sujeito a} \quad \sum_{j=1}^n a_{ij} x_j \leq b_i \quad i = 1, \dots, m \quad (2)$$

$$x_j \geq 0 \quad j = 1, \dots, n \quad (3)$$

A Equação 4 descreve a *função objetivo*, isto é, a função linear que será maximizada (ou

minimizada) em um programa linear, no qual x_j são chamadas de *variáveis de decisão*. A Equação 5 representa as *restrições* que delimitam os possíveis valores destas variáveis. Por fim, a Equação 6 indica uma *restrição de não negatividade*, já que em muitos problemas não faz sentido atribuir valores negativos para as variáveis de decisão.

Denomina-se *solução viável* uma atribuição de valores a x_j que satisfaz todas as restrições impostas ao problema. Já uma *solução ótima* é uma solução viável que maximiza a função objetivo. Vale destacar que podem existir mais de uma solução ótima para o mesmo problema ou até mesmo não existir solução ótima. No caso de não existir nenhuma solução viável, o problema é chamado de *inviável* e, para o caso em que as soluções viáveis permitem que a função objetivo cresça indefinidamente, os problemas são chamados de *ilimitados* [5].

Entre as técnicas utilizadas para resolver problemas de PL, está o *método simplex* [5]. A partir de uma solução viável inicial, o *simplex* realiza iterativamente o processo de pivotamento, isto é, a troca de variáveis, visando melhorar o valor da função objetivo. Apesar de ter complexidade exponencial no pior caso, o *simplex* é rápido, na prática.

Um dos conceitos centrais em Programação Linear é a *dualidade*, isto é, a partir de um programa linear $LP(P)$ de maximização, chamado de *primal*, é possível obter um programa $LP(D)$ de minimização, chamado de *dual*.

$$\text{minimize} \quad \sum_{i=1}^m b_i y_i \quad (4)$$

$$\text{sujeito a} \quad \sum_{i=1}^m a_{ij} y_i \geq c_j \quad j = 1, \dots, n \quad (5)$$

$$y_i \geq 0 \quad i = 1, \dots, m \quad (6)$$

Qualquer problema linear pode ser associado a um dual, cuja função objetivo e restrições são construídas a partir dos coeficientes e parâmetros do primal.

Um *Programa Linear Inteiro* (PLI) é um PL com a restrição adicional de que todas

as variáveis devem assumir valores inteiros. Problemas de PLI são NP-Completo, mas, na prática, é possível resolver instâncias específicas de PLI de forma eficiente, graças ao desenvolvimento de algoritmos exatos, técnicas de otimização e heurísticas eficazes [13].

Uma das técnicas utilizadas para resolver problemas de PLI é o método *branch-and-bound* [13]. Iterativamente, o algoritmo resolve a *relaxação linear* do PLI, isto é, o PL obtido ao remover as restrições de integralidade, e, caso a solução não seja inteira, divide o problema original em partes menores, formando uma árvore de subproblemas. Caso o valor da solução da relaxação linear no nó não seja viável ou não supere o melhor valor encontrado até o momento, não é necessário explorar os filhos deste nó, o que reduz o espaço de busca. Ainda, se a solução da relaxação linear obtida em um nó for inteira, esta solução é viável para o PLI original e pode ser utilizada para atualizar a melhor solução encontrada, denominada *incumbente*.

3.2 Árvores de Decisão Ótimas

[a escrever]

3.3 Implementações e Experimentos

[a escrever]

4 Conclusão

[a escrever]

Durante o Estudo Dirigido, diversos aspectos colaboraram para o amadurecimento profissional e acadêmico da aluna. Entre eles, é importante mencionar a construção de uma base de conhecimentos em Programação Linear Inteira. Através tanto do estudo individual, como das reuniões do grupo de pesquisa semanais, a estudante consolidou o entendimento de técnicas de PLI e como elas são aplicadas no contexto de otimização.

Além disso, a leitura de artigos sobre árvores de decisão ótimas colaborou para a compreensão do contexto de uso dessa técnica de categorização...

- Matérias do curso que eu usei:

* MC358, MC458, MC558 * Combinatória Poliédrica

Referências

- [1] S. Aghaei, A. Gómez e P. Vayanos, *Strong Optimal Classification Trees*, 2021. DOI: 10.48550/ARXIV.2103.15965.
- [2] D. Bertsimas e J. Dunn, “Optimal classification trees,” *Machine Learning*, v. 106, n. 7, 2017, ISSN: 1573-0565. DOI: 10.1007/s10994-017-5633-9.
- [3] D. Bertsimas, J. Dunn, G. C. Velmahos e H. M. A. Kaafarani, “Surgical Risk Is Not Linear: Derivation and Validation of a Novel, User-friendly, and Machine-learning-based Predictive Optimal Trees in Emergency Surgery Risk (POTTER) Calculator,” *Annals of Surgery*, v. 268, n. 4, 2018. DOI: 10.1097/SLA.0000000000002956.
- [4] H. Chan, E. Rice, P. Vayanos, M. Tambe e M. Morton, “From Empirical Analysis to Public Policy: Evaluating Housing Systems for Homeless Youth,” em *Machine Learning and Knowledge Discovery in Databases*. Springer International Publishing, 2019, ISBN: 9783030109974. DOI: 10.1007/978-3-030-10997-4_5.
- [5] V. Chvátal, *Linear Programming* (Series of books in the mathematical sciences). W. H. Freeman, 1983, ISBN: 9780716715870.
- [6] V. G. Costa e C. E. Pedreira, “Recent advances in decision trees: an updated survey,” *Artificial Intelligence Review*, v. 56, n. 5, 2022, ISSN: 1573-7462. DOI: 10.1007/s10462-022-10275-5.
- [7] I. Genc, R. Diao, V. Vittal, S. Kolluri e S. Mandal, “Decision Tree-Based Preventive and Corrective Control Applications for Dynamic Security Enhancement in Power Systems,” *IEEE Transactions on Power Systems*, v. 25, n. 3, 2010, ISSN: 1558-0679. DOI: 10.1109/tpwrs.2009.2037006.
- [8] “Gurobi Optimizer,” acesso em 26 de out. de 2025. endereço: <https://www.gurobi.com>.
- [9] L. Hyafil e R. L. Rivest, “Constructing optimal binary decision trees is NP-complete,” *Information Processing Letters*, v. 5, n. 1, 1976, ISSN: 0020-0190. DOI: 10.1016/0020-0190(76)90095-8.

- [10] J. G. M. van der Linden, D. Vos, M. M. de Weerdt, S. Verwer e E. Demirović, *Optimal or Greedy Decision Trees? Revisiting their Objectives, Tuning, and Performance*, 2024. DOI: 10.48550/ARXIV.2409.12788.
- [11] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, v. 1, n. 5, 2019, ISSN: 2522-5839. DOI: 10.1038/s42256-019-0048-x.
- [12] S. Verwer e Y. Zhang, “Learning Optimal Classification Trees Using a Binary Linear Program Formulation,” *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 33, n. 01, 2019, ISSN: 2159-5399. DOI: 10.1609/aaai.v33i01.33011624.
- [13] L. A. Wolsey, *Integer programming*, Second edition. Hoboken, NJ: Wiley, 2021, 1316 pp., Description based upon online resource; title from PDF title page (viewed September 28, 2020), ISBN: 9781119606529.